Grad-CAM

Fondements mathématiques, intuition visuelle et interprétation

Document détaillé pour comprendre l'explicabilité locale en vision par ordinateur

Yann Smatti

Mars 2026

Explainable AI · CNN · Imagerie médicale · Vision par ordinateur

Table des matières

1 Introduction **3**

2 Pourquoi a-t-on besoin d'explicabilité ? **3**

2.1 Le problème de la boîte noire . . . 3

2.2 Pourquoi c'est critique en médecine . . . 3

3 Ce qu'un CNN voit réellement **4**

3.1 L'image comme matrice . . . 4

3.2 Convolutions et cartes de caractéristiques . . . 4

3.3 Interprétation intuitive . . . 4

4 Objectif de Grad-CAM **4**

5 De la prédiction à la dérivée **5**

5.1 Score de classe . . . 5

5.2 Pourquoi regarder le gradient ? . . . 5

6 Formulation mathématique de Grad-CAM **5**

6.1 Poids d'importance par canal . . . 5

6.2 Sens de la moyenne spatiale . . . 5

6.3 Combinaison linéaire des cartes . . . 6

6.4 Pourquoi la fonction ReLU ? . . . 6

7 Exemple jouet détaillé **6**

8 Pourquoi la dernière couche convolutive ? **7**

9 Algorithme de Grad-CAM **7**
9.1 Étapes conceptuelles . . . 7
9.2 Pseudo-code . . . 8

10 Interprétation géométrique **8**

11 Superposition à l'image originale **8**

12 Exemple de lecture d'une heatmap **9**

13 Spécificités en imagerie médicale **9**
13.1 Points forts . . . 9
13.2 Limites importantes . . . 9

14 Grad-CAM, CAM et variantes **9**
14.1 CAM classique . . . 9
14.2 Grad-CAM++ . . . 10
14.3 Guided Grad-CAM . . . 10

15 Pourquoi Grad-CAM marche-t-il souvent bien ? **10**

16 Exemple conceptuel de pipeline **10**

17 Implémentation pratique **10**

18 Points de vigilance méthodologiques **11**

19 Résumé intuitif **11**

20 Comparaison avec d'autres méthodes d'explicabilité **11**
20.1 Class Activation Mapping (CAM) . . . 11
20.2 Grad-CAM . . . 12
20.3 Grad-CAM++ . . . 12

21 Implémentation TensorFlow **12**

22 Application dans le projet MedVision **13**

23 Analyse d'une heatmap médicale **13**

24 Bonnes pratiques **14**

25 Conclusion **14**

1 Introduction

Les réseaux de neurones convolutifs obtiennent d'excellentes performances en classification d'images, mais ils sont souvent perçus comme des *boîtes noires*. Un modèle peut prédire qu'une image contient une pathologie avec une forte confiance sans indiquer clairement *pourquoi* il prend cette décision.

Cette absence d'interprétabilité est particulièrement problématique en imagerie médicale. Un clinicien ne peut pas se contenter d'une probabilité ; il veut savoir quelles régions de l'image ont influencé le modèle.

Grad-CAM, pour *Gradient-weighted Class Activation Mapping*, est une méthode d'explicabilité locale qui répond à la question suivante :

Quelles zones de l'image ont le plus contribué à la prédiction d'une classe donnée ?

Le but de ce document est d'expliquer Grad-CAM :

— intuitivement ;
— mathématiquement ;
— algorithmiquement ;
— avec un angle spécifique à l'imagerie médicale.

2 Pourquoi a-t-on besoin d'explicabilité ?

2.1 Le problème de la boîte noire

Considérons un réseau de neurones convolutif réalisant une classification binaire. À partir d'une image x, il produit

$$P(\text{maladie} \mid x) = 0.93.$$

Cette sortie est utile, mais elle ne nous dit pas si le modèle regarde :

— la véritable lésion ;
— un artefact d'acquisition ;
— une annotation textuelle ;
— un bord noir de l'image.

Deux modèles peuvent produire la même sortie numérique, mais pour des raisons très différentes.

2.2 Pourquoi c'est critique en médecine

En imagerie médicale, une bonne explication visuelle permet de :

— vérifier que le réseau regarde la bonne région anatomique ;
— détecter des biais du dataset ;
— repérer des comportements aberrants ;
— renforcer ou diminuer la confiance dans le modèle.

Grad-CAM ne remplace pas une validation clinique, mais fournit une **explication locale** de la décision.

3 Ce qu'un CNN voit réellement

3.1 L'image comme matrice

Une image en niveaux de gris est une matrice

$$I \in \mathbb{R}^{H \times W},$$

et une image couleur un tenseur

$$I \in \mathbb{R}^{H \times W \times 3}.$$

Le réseau ne voit pas une « lésion » ou un « poumon ». Il voit seulement des nombres.

3.2 Convolutions et cartes de caractéristiques

Dans un CNN, les premières couches appliquent des filtres convolutifs qui extraient des motifs locaux :

- bords ;
- textures ;
- petits contrastes ;
- structures plus complexes à mesure que l'on monte dans le réseau.

Chaque filtre produit une **carte de caractéristiques**, aussi appelée *feature map*. On les note généralement

$$A^1, A^2, \ldots, A^K.$$

Chaque carte A^k est une image intermédiaire, souvent de plus petite taille spatiale que l'image d'origine.

3.3 Interprétation intuitive

On peut voir une feature map comme un détecteur spatial de motifs. Si une région donnée de l'image active fortement un certain filtre, alors la valeur correspondante dans la feature map sera grande.

Dans les couches profondes, ces cartes ne détectent plus seulement des bords simples mais des motifs plus abstraits et plus utiles pour la classe finale.

4 Objectif de Grad-CAM

Grad-CAM cherche à répondre à cette question :

Parmi les cartes de caractéristiques finales, lesquelles sont les plus importantes pour la classe cible, et où sont-elles actives spatialement ?

L'idée générale est de :

1) choisir une classe cible c ;
2) mesurer l'influence de chaque feature map sur le score de cette classe ;
3) combiner les feature maps avec ces poids d'influence ;
4) obtenir une heatmap superposable à l'image originale.

5 De la prédiction à la dérivée

5.1 Score de classe

Soit y^c le score associé à la classe c. Selon l'implémentation, y^c peut désigner :

— le logit avant softmax ;
— ou plus rarement la probabilité après softmax.

En pratique, on préfère souvent utiliser le **logit** pour éviter certains effets de saturation.

5.2 Pourquoi regarder le gradient ?

Le gradient permet de mesurer la sensibilité du score y^c aux activations internes du réseau. Si l'on note par A^k_{ij} la valeur de la feature map k à la position spatiale (i, j), alors

$$\frac{\partial y^c}{\partial A^k_{ij}}$$

mesure l'effet d'une petite variation de A^k_{ij} sur le score de la classe c.

Interprétation :

— si cette dérivée est grande et positive, augmenter cette activation augmente le score de la classe ;
— si elle est négative, cette activation pousse plutôt contre la classe ;
— si elle est proche de zéro, cette activation a peu d'influence.

6 Formulation mathématique de Grad-CAM

6.1 Poids d'importance par canal

Pour chaque canal k de la dernière couche convolutive, Grad-CAM définit un poids

$$\alpha^c_k = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A^k_{ij}},$$

où Z est le nombre total de positions spatiales :

$$Z = H'W'.$$

Ici, H' et W' sont la hauteur et la largeur des feature maps de la dernière couche convolutionnelle.

6.2 Sens de la moyenne spatiale

Le terme

$$\frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A^k_{ij}}$$

est une moyenne globale des gradients du canal k.

Idée : au lieu d'examiner séparément chaque position, on résume l'influence globale du canal k sur la classe c par un seul scalaire α_k^c.

Ainsi :

— un canal très utile pour la classe obtient un poids élevé ;
— un canal peu utile obtient un poids faible ;
— un canal nuisible peut obtenir un poids négatif.

6.3 Combinaison linéaire des cartes

Une fois les poids calculés, la carte Grad-CAM est définie par

$$L^c_{\text{GradCAM}} = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right).$$

Il s'agit d'une combinaison linéaire pondérée des feature maps.

6.4 Pourquoi la fonction ReLU ?

La fonction

$$\text{ReLU}(x) = \max(0, x)$$

supprime les contributions négatives.

L'idée est la suivante : pour expliquer *pourquoi* le modèle a choisi la classe c, on préfère mettre en évidence les régions qui **augmentent** le score de cette classe, plutôt que celles qui le diminuent.

Autrement dit, Grad-CAM cherche les *preuves positives* en faveur de la classe cible.

7 Exemple jouet détaillé

Considérons trois feature maps finales :

$$A^1 = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 0 \end{pmatrix}, \qquad A^2 = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 2 & 2 \\ 1 & 2 & 1 \end{pmatrix}, \qquad A^3 = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 8 & 2 \\ 1 & 2 & 1 \end{pmatrix}.$$

Supposons que pour la classe cible c, les poids obtenus soient :

$$\alpha_1^c = 0.1, \qquad \alpha_2^c = 0.3, \qquad \alpha_3^c = 0.9.$$

Alors,

$$L^c = \text{ReLU}(0.1A^1 + 0.3A^2 + 0.9A^3).$$

Calculons :

$$0.1A^1 = \begin{pmatrix} 0 & 0.1 & 0 \\ 0.1 & 0.3 & 0.1 \\ 0 & 0.1 & 0 \end{pmatrix},$$

$$0.3A^2 = \begin{pmatrix} 0 & 0 & 0.3 \\ 0 & 0.6 & 0.6 \\ 0.3 & 0.6 & 0.3 \end{pmatrix},$$

$$0.9A^3 = \begin{pmatrix} 0.9 & 1.8 & 0.9 \\ 1.8 & 7.2 & 1.8 \\ 0.9 & 1.8 & 0.9 \end{pmatrix}.$$

La somme vaut

$$L^c_{\text{avant ReLU}} = \begin{pmatrix} 0.9 & 1.9 & 1.2 \\ 1.9 & 8.1 & 2.5 \\ 1.2 & 2.5 & 1.2 \end{pmatrix}.$$

Toutes les valeurs étant positives, ReLU ne change rien ici.

Interprétation : la plus forte valeur se situe au centre. La heatmap finale indiquera donc que le modèle regarde essentiellement la région centrale pour justifier sa prédiction.

8 Pourquoi la dernière couche convolutive ?

Grad-CAM s'applique généralement à la **dernière couche convolutionnelle**.

Pourquoi ? Parce qu'elle offre un compromis entre :

— **richesse sémantique** : les couches profondes représentent des motifs complexes utiles à la classification ;

— **structure spatiale** : contrairement aux couches denses finales, les convolutions conservent une organisation dans l'espace.

Les couches très basses ont une grande résolution spatiale, mais leurs activations sont souvent trop primitives. Les couches totalement connectées contiennent une information très abstraite, mais perdent la localisation spatiale.

La dernière couche convolutionnelle est donc l'endroit naturel pour produire une carte explicative locale.

9 Algorithme de Grad-CAM

9.1 Étapes conceptuelles

Soit un réseau convolutif et une image d'entrée x.

1) Faire une passe avant dans le réseau pour obtenir le score y^c de la classe cible.
2) Extraire les feature maps A^k de la dernière couche convolutionnelle.
3) Calculer les gradients de y^c par rapport à chaque élément A^k_{ij}.
4) Calculer les poids α^c_k par moyenne spatiale des gradients.
5) Former la combinaison pondérée $\sum_k \alpha^c_k A^k$.

6) Appliquer ReLU.
7) Redimensionner la heatmap à la taille de l'image originale.
8) Superposer la heatmap à l'image.

9.2 Pseudo-code

Algorithme Grad-CAM

Entrée : image x, modèle f, classe cible c
Sortie : heatmap explicative L^c

1) Calculer la passe avant et stocker les activations A^k.
2) Calculer le score de classe y^c.
3) Calculer les gradients $\partial y^c / \partial A^k_{ij}$.
4) Pour chaque canal k, calculer

$$\alpha^c_k = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A^k_{ij}}.$$

5) Combiner les cartes :

$$L^c = \mathrm{ReLU}\left(\sum_k \alpha^c_k A^k \right).$$

6) Normaliser et interpoler la carte à la taille de l'image d'origine.

10 Interprétation géométrique

On peut voir les activations locales de la dernière couche convolutive comme un ensemble de directions ou de motifs dans un espace de représentation. Le score de classe y^c dépend de ces activations.

Le gradient indique comment ce score varie localement. Les poids α^c_k résument l'importance de chaque canal dans cette variation.

Ainsi, Grad-CAM réalise deux opérations :

— une **pondération sémantique** des canaux par les gradients ;
— une **projection spatiale** des activations utiles à la classe.

On peut résumer cela par :

Heatmap = où le réseau s'active × à quel point cette activation aide la classe cible.

11 Superposition à l'image originale

La carte L^c_{GradCAM} est de petite taille, par exemple 7×7 ou 14×14. Pour être lisible, on :

— la normalise dans $[0, 1]$;
— l'interpole à la taille de l'image d'entrée ;
— la représente sous forme de heatmap ;
— la superpose à l'image originale.

Mathématiquement, si $\widetilde{L}^c$ est la version interpolée, on peut construire une image explicative de type

$$I_{\text{exp}} = (1-\lambda)I + \lambda H(\widetilde{L}^c),$$

où H désigne une colorisation thermique et $\lambda \in [0,1]$ un coefficient de mélange.

12 Exemple de lecture d'une heatmap

Supposons qu'un modèle de radiographie thoracique prédise :

$$P(\text{pneumonie}) = 0.91.$$

Trois situations sont possibles :

1) La heatmap se concentre sur une opacité pulmonaire cohérente avec la pathologie : c'est rassurant.
2) La heatmap se concentre sur le bord de l'image ou sur une annotation : cela révèle un biais.
3) La heatmap est diffuse, peu localisée, ou instable : cela suggère une explication peu robuste.

Grad-CAM n'est donc pas seulement un outil de visualisation esthétique ; c'est aussi un outil de **diagnostic du modèle lui-même**.

13 Spécificités en imagerie médicale

13.1 Points forts

En imagerie médicale, Grad-CAM est utile pour :

— vérifier la cohérence anatomique ;
— produire des visualisations compréhensibles par les cliniciens ;
— détecter des corrélations parasites ;
— documenter qualitativement les sorties du modèle.

13.2 Limites importantes

Il faut cependant rester prudent.

Grad-CAM :

— n'est pas une preuve causale ;
— dépend du choix de la couche convolutionnelle ;
— peut produire des heatmaps visuellement séduisantes mais peu informatives ;
— donne une explication **locale** pour une prédiction donnée, pas une compréhension globale du modèle.

14 Grad-CAM, CAM et variantes

14.1 CAM classique

La méthode CAM originale suppose une architecture particulière avec :

— une dernière couche convolutionnelle ;
— un global average pooling ;
— une couche linéaire finale.

Grad-CAM généralise cette idée en utilisant les gradients, ce qui lui permet de fonctionner avec une plus grande variété d'architectures.

14.2 Grad-CAM++

Grad-CAM++ modifie la pondération des activations pour mieux gérer les cas où plusieurs occurrences d'un même objet apparaissent dans l'image.

14.3 Guided Grad-CAM

Guided Grad-CAM combine Grad-CAM avec des méthodes de backpropagation guidée afin d'obtenir des cartes plus fines, mais souvent moins directement interprétables cliniquement.

15 Pourquoi Grad-CAM marche-t-il souvent bien ?

Deux raisons principales expliquent son succès :

1) Les dernières convolutions conservent une structure spatiale.
2) Les gradients donnent une mesure locale de l'influence sur la classe.

Le mélange des deux fournit une explication à la fois :

— sémantique ;
— localisée ;
— relativement simple à calculer.

16 Exemple conceptuel de pipeline

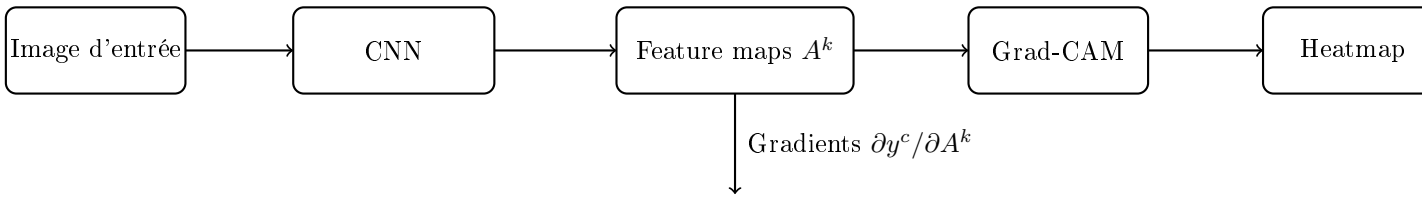

17 Implémentation pratique

En pratique, avec TensorFlow ou PyTorch, on procède ainsi :

— on construit un modèle auxiliaire qui renvoie à la fois les activations de la dernière couche convolutionnelle et la sortie du réseau ;
— on utilise l'autodifférentiation pour calculer les gradients ;
— on calcule les poids moyens par canal ;
— on forme la heatmap ;
— on l'affiche après interpolation.

Cette méthode est rapide, ne nécessite pas de réentraîner le modèle et s'applique image par image.

18 Points de vigilance méthodologiques

Quand on utilise Grad-CAM dans un projet sérieux, il faut :

— vérifier plusieurs images, pas seulement un exemple réussi ;
— comparer des cas vrais positifs, faux positifs et faux négatifs ;
— inspecter visuellement si le modèle regarde la région pertinente ;
— conserver un esprit critique sur l'interprétation.

Une heatmap convaincante sur trois images n'implique pas que le modèle est fiable globalement.

19 Résumé intuitif

On peut résumer Grad-CAM de la manière suivante :

1) Le CNN transforme l'image en cartes internes de motifs.
2) Certaines de ces cartes aident davantage la classe cible que d'autres.
3) Les gradients permettent de mesurer cette aide.
4) On recombine ces cartes avec leurs poids d'importance.
5) On obtient une carte de chaleur qui indique où le modèle regarde.

Grad-CAM montre quelles régions de l'image contribuent positivement à la prédiction d'une classe donnée.

20 Comparaison avec d'autres méthodes d'explicabilité

20.1 Class Activation Mapping (CAM)

La méthode CAM (Class Activation Mapping) est l'ancêtre direct de Grad-CAM.

Elle suppose une architecture spécifique :

— dernière couche convolutionnelle
— global average pooling
— couche linéaire finale

Dans ce cas, la carte d'activation de classe peut être calculée directement :

$$L^c = \sum_k w_k^c A^k$$

où

— A^k est la feature map k
— w_k^c est le poids de la classe c dans la couche finale

Cette approche est simple mais impose une architecture particulière.

Grad-CAM généralise cette idée en utilisant les gradients.

20.2 Grad-CAM

Grad-CAM fonctionne avec n'importe quel CNN.

La pondération est obtenue via les gradients :

$$\alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}$$

et la carte finale :

$$L^c = ReLU\left(\sum_k \alpha_k^c A^k\right)$$

Cette méthode permet donc d'expliquer les prédictions sans modifier l'architecture du réseau.

20.3 Grad-CAM++

Grad-CAM++ améliore la localisation lorsque plusieurs objets sont présents.

Les poids deviennent :

$$\alpha_{ij}^{kc}$$

et sont calculés avec des dérivées d'ordre supérieur.

Cela permet :

— meilleure localisation
— détection de multiples objets

mais augmente le coût de calcul.

21 Implémentation TensorFlow

Une implémentation simplifiée est la suivante.

```
with tf.GradientTape() as tape:

    conv_outputs, predictions = grad_model(image)

    loss = predictions[:, class_index]

grads = tape.gradient(loss, conv_outputs)

pooled_grads = tf.reduce_mean(grads, axis=(0,1,2))

conv_outputs = conv_outputs[0]

heatmap = tf.reduce_sum(pooled_grads * conv_outputs, axis=-1)
```

```
heatmap = tf.maximum(heatmap,0)

heatmap = heatmap / tf.reduce_max(heatmap)
```

Les étapes correspondent exactement à l'algorithme mathématique.

22 Application dans le projet MedVision

Dans le projet MedVision, Grad-CAM est utilisé pour interpréter les prédictions du modèle CNN entraîné sur des radiographies.

Le pipeline complet est :

1. Chargement de l'image médicale
2. Prétraitement et normalisation
3. Prédiction par le CNN
4. Extraction de la dernière couche convolutionnelle
5. Calcul de la heatmap Grad-CAM
6. Redimensionnement
7. Superposition avec l'image originale

Cette heatmap permet de vérifier si le modèle regarde réellement une région pathologique.

23 Analyse d'une heatmap médicale

Trois cas sont possibles.

Cas 1 : heatmap cohérente

La heatmap est localisée sur la lésion.

Cela suggère que le modèle a appris un signal clinique pertinent.

Cas 2 : heatmap parasite

La heatmap est localisée sur :

— un bord d'image
— une annotation
— un artefact du scanner

Cela révèle un biais du dataset.

Cas 3 : heatmap diffuse

La carte est dispersée et peu informative.

Cela peut indiquer :

— un modèle instable
— un manque de données
— une mauvaise architecture

24 Bonnes pratiques

Pour analyser un modèle avec Grad-CAM :

— inspecter plusieurs images
— analyser vrais positifs et faux positifs
— vérifier la cohérence anatomique
— comparer différentes couches convolutionnelles

Grad-CAM est un outil d'analyse du modèle, pas une preuve absolue.

25 Conclusion

Grad-CAM est une méthode d'explicabilité locale élégante, simple et très utilisée en vision par ordinateur. Elle combine deux idées fondamentales :

— la structure spatiale conservée par les couches convolutionnelles ;
— l'information de sensibilité fournie par les gradients.

Son succès vient du fait qu'elle offre une explication visuelle directe, souvent suffisamment parlante pour être utilisée dans des contextes appliqués, notamment en imagerie médicale.

Il faut toutefois garder en tête qu'il s'agit d'un outil d'interprétation *partiel*. Grad-CAM aide à comprendre une décision, mais ne résout pas à lui seul toutes les questions de robustesse, de causalité ou de confiance.