MedVision

Fondements Mathématiques et Algorithmiques du Pipeline

Analyse détaillée avec interprétations intuitives
pour étudiants en L2–L3 / CPGE

Yann Smatti

Mars 2026

Pipeline ML · TensorFlow · Computer Vision · Imagerie médicale

Table des matières

1 Introduction et prérequis **2**

2 Représentation mathématique d'une image **2**

2.1 Une image comme fonction discrète 2

2.2 Image comme vecteur de grande dimension 2

3 Prétraitement des images **3**

3.1 Normalisation 3

3.2 Redimensionnement 3

3.3 Augmentation des données 3

4 Convolution **4**

4.1 Définition discrète 4

4.2 Interprétation intuitive 4

4.3 Lien avec l'analyse 4

5 Le neurone artificiel **4**

5.1 Interprétation géométrique 5

6 Réseaux de neurones convolutifs **5**

6.1 Principe 5

6.2 Pourquoi c'est plus efficace qu'une couche dense ? 5

7 Fonctions d'activation **5**

7.1 ReLU 5

7.2 Sigmoïde 6

8 Pooling **6**

9 Descente de gradient **6**

9.1 Principe général 6

9.2 Interprétation 6

10 Rétropropagation **7**

11 Fonction de perte **7**

11.1 Classification binaire : entropie croisée 7

11.2 Pourquoi cette loss ? 7

12 Transfer learning **7**

12.1 Idée générale 7

12.2 Pourquoi cela marche ? 7

13 Évaluation du modèle **8**

13.1 Matrice de confusion 8

13.2 Accuracy 8

13.3 Précision 8

13.4 Rappel 8

13.5 Score F1 8

14 Courbe ROC et AUC **8**

15 Explicabilité : Grad-CAM **9**

16 Lien direct avec le projet MedVision **9**

17 Conclusion **9**

1 Introduction et prérequis

Ce document explique les fondements mathématiques du projet **MedVision**, un pipeline de vision par ordinateur appliqué à l'analyse d'images médicales.

L'idée générale du projet est la suivante :

1) on charge des images médicales ;
2) on les prétraite ;
3) on les passe dans un réseau de neurones convolutif ;
4) on entraîne le modèle à reconnaître une classe pathologique ou non ;
5) on évalue rigoureusement ses performances.

Prérequis utiles :

— algèbre linéaire : vecteurs, matrices, produit scalaire ;
— analyse : dérivées partielles, gradient, règle de chaîne ;
— probabilités : variables aléatoires, espérance, variance ;
— un peu d'informatique scientifique.

Philosophie du document : chaque notion est présentée en trois niveaux :

— l'idée intuitive ;
— la formulation mathématique ;
— le lien direct avec le projet MedVision.

2 Représentation mathématique d'une image

2.1 Une image comme fonction discrète

Une image numérique en niveaux de gris peut être vue comme une fonction

$$I : \{1, \dots, H\} \times \{1, \dots, W\} \to [0, 255]$$

où :

— H désigne la hauteur ;
— W désigne la largeur ;
— $I(i, j)$ est l'intensité lumineuse du pixel situé en position (i, j).

Pour une image couleur RGB, on a en réalité trois canaux, donc

$$I \in \mathbb{R}^{H \times W \times 3}.$$

Intuition. Une image couleur est donc une sorte de *tenseur d'ordre 3* : hauteur, largeur, canal.

2.2 Image comme vecteur de grande dimension

Si l'on « déroule » l'image, on peut aussi la considérer comme un vecteur

$$x \in \mathbb{R}^{3HW}.$$

Par exemple, pour une image $224 \times 224 \times 3$:

$$3HW = 3 \times 224 \times 224 = 150\,528.$$

Donc une seule image vit dans un espace de dimension 150 528.

Conséquence. Le rôle du modèle est d'apprendre une fonction

$$f : \mathbb{R}^{150528} \to \mathbb{R}^K,$$

où K est le nombre de classes.

3 Prétraitement des images

3.1 Normalisation

Les pixels d'une image sont souvent codés entre 0 et 255. Pour stabiliser l'entraînement, on normalise :

$$x' = \frac{x}{255}.$$

Ainsi :

$$x' \in [0, 1].$$

Pourquoi ? Parce que les réseaux de neurones apprennent mieux quand les données sont sur des échelles comparables.

3.2 Redimensionnement

Dans MedVision, les images sont redimensionnées en général à

$$224 \times 224$$

pour être compatibles avec des architectures pré-entraînées standards comme ResNet ou EfficientNet.

Interprétation. On impose un format commun à toutes les images, exactement comme on met tous les vecteurs dans le même espace avant de faire de l'algèbre linéaire.

3.3 Augmentation des données

On applique souvent des transformations comme :

- rotation ;
- symétrie horizontale ;
- zoom léger ;
- variation de contraste.

Mathématiquement, on applique une transformation

$$T : \mathcal{X} \to \mathcal{X}$$

à une image x, ce qui donne une nouvelle image

$$\widetilde{x} = T(x).$$

Idée. On ne change pas la nature médicale de l'image, mais on enrichit artificiellement le dataset.

4 Convolution

4.1 Définition discrète

La convolution discrète entre une image I et un noyau K est définie par

$$(I * K)(i, j) = \sum_m \sum_n I(i - m, j - n)K(m, n).$$

Dans la pratique, le noyau est petit, par exemple 3×3 ou 5×5.

4.2 Interprétation intuitive

Pour calculer la nouvelle valeur d'un pixel, on combine les valeurs des pixels voisins avec des poids donnés par le noyau.

Exemple de noyau détectant des contours verticaux :

$$K = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}.$$

Si l'image contient un bord vertical, ce filtre réagit fortement.

4.3 Lien avec l'analyse

En analyse continue, la convolution est

$$(f * g)(x) = \int_{\mathbb{R}} f(t)g(x - t)\, dt.$$

En image, on passe simplement à une version discrète en deux dimensions.

Idée importante. La convolution agit comme un *filtrage local* : elle extrait des motifs élémentaires comme les bords, textures, petits contrastes.

5 Le neurone artificiel

Un neurone artificiel calcule

$$y = \varphi(w^\top x + b),$$

où :

— x est le vecteur d'entrée ;
— w est le vecteur de poids ;
— b est un biais ;
— φ est une fonction d'activation.

5.1 Interprétation géométrique

L'équation

$$w^\top x + b = 0$$

définit un hyperplan.

Donc un neurone simple sépare l'espace en deux régions.

Vision géométrique. Un neurone décide de quel côté d'un hyperplan se trouve le point x.

6 Réseaux de neurones convolutifs

6.1 Principe

Un CNN empile plusieurs blocs :
— convolution ;
— activation ;
— pooling ;
— couches denses finales.
Une couche convolutive calcule

$$Y_{i,j,f} = \sum_{c=1}^{C} \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} W_{m,n,c,f} X_{i+m,j+n,c} + b_f.$$

Ici :
— X est l'entrée ;
— W est le filtre ;
— f indexe la carte de caractéristiques obtenue.

6.2 Pourquoi c'est plus efficace qu'une couche dense ?

Une couche dense relie tous les pixels à tous les neurones. Une convolution :
— utilise des voisinages locaux ;
— partage les mêmes poids sur toute l'image.
Donc elle a beaucoup moins de paramètres.

7 Fonctions d'activation

7.1 ReLU

La fonction la plus classique est

$$\mathrm{ReLU}(x) = \max(0, x).$$

Pourquoi ? Elle introduit une non-linéarité indispensable. Sans non-linéarité, un réseau profond resterait essentiellement une transformation linéaire globale.

7.2 Sigmoïde

Pour une classification binaire, on utilise souvent :

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

Cette fonction renvoie une probabilité dans $[0, 1]$.

8 Pooling

Le pooling sert à réduire la taille spatiale des représentations.

Exemple en max-pooling sur une fenêtre 2×2 :

$$\begin{pmatrix} 1 & 3 \\ 2 & 0 \end{pmatrix} \mapsto 3.$$

Interprétation. On garde la réponse la plus forte localement. Cela rend le modèle plus robuste à de petits déplacements des motifs.

9 Descente de gradient

9.1 Principe général

On cherche à minimiser une fonction de coût $L(\theta)$. La mise à jour de base est

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t),$$

où :

- θ désigne les paramètres ;
- η est le taux d'apprentissage ;
- ∇L est le gradient.

9.2 Interprétation

Le gradient pointe dans la direction de plus forte augmentation. Donc, pour minimiser, on se déplace dans la direction opposée.

Analogie. C'est comme descendre une montagne en regardant la pente locale.

10 Rétropropagation

La rétropropagation repose sur la règle de chaîne.

Si

$$f(x) = f_3(f_2(f_1(x))),$$

alors

$$\frac{df}{dx} = \frac{df_3}{df_2} \cdot \frac{df_2}{df_1} \cdot \frac{df_1}{dx}.$$

Sens. On calcule comment une petite variation d'un paramètre en amont influence la perte finale.

C'est cette idée qui permet d'entraîner efficacement des réseaux profonds.

11 Fonction de perte

11.1 Classification binaire : entropie croisée

Pour une vérité terrain $y \in \{0, 1\}$ et une probabilité prédite p :

$$L(y, p) = -\big(y \log p + (1 - y) \log(1 - p)\big).$$

Interprétation. Si le modèle attribue une faible probabilité à la bonne classe, la pénalité est grande.

11.2 Pourquoi cette loss ?

Parce qu'elle est bien adaptée aux probabilités et qu'elle punit fortement les erreurs confiantes.

12 Transfer learning

12.1 Idée générale

On réutilise un réseau déjà entraîné sur une grande base d'images, par exemple ImageNet.

On écrit conceptuellement :

$$f(x) = g(h(x)),$$

où :

- $h(x)$ extrait des caractéristiques générales ;
- $g(x)$ est la tête de classification adaptée à notre tâche.

12.2 Pourquoi cela marche ?

Les premières couches apprennent des structures génériques :

— bords ;
— textures ;
— motifs élémentaires.

Ces motifs sont utiles dans beaucoup de tâches visuelles, y compris en imagerie médicale.

13 Évaluation du modèle

13.1 Matrice de confusion

Pour une classification binaire, on distingue :

— vrais positifs (TP),
— faux positifs (FP),
— vrais négatifs (TN),
— faux négatifs (FN).

13.2 Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

13.3 Précision

$$\text{Precision} = \frac{TP}{TP + FP}.$$

13.4 Rappel

$$\text{Recall} = \frac{TP}{TP + FN}.$$

13.5 Score F1

$$F_1 = 2\frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Pourquoi le F1 est utile ? Parce qu'il pénalise les modèles déséquilibrés : il faut être bon à la fois en précision et en rappel.

14 Courbe ROC et AUC

La courbe ROC trace :

— le taux de vrais positifs ;
— en fonction du taux de faux positifs.

On définit :

$$\mathrm{TPR} = \frac{TP}{TP + FN}, \qquad \mathrm{FPR} = \frac{FP}{FP + TN}.$$

L'aire sous la courbe ROC est l'AUC.

Interprétation. Plus l'AUC est proche de 1, meilleur est le classifieur.

15 Explicabilité : Grad-CAM

Grad-CAM permet de visualiser les régions de l'image qui influencent la décision.

Si A^k désigne la k-ième carte de caractéristiques de la dernière couche convolutive, on calcule

$$\alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{i,j}^k}.$$

Puis :

$$L_{\mathrm{GradCAM}}^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k \right).$$

Idée. On obtient une carte de chaleur montrant *où* le réseau regarde pour prendre sa décision.

16 Lien direct avec le projet MedVision

Dans MedVision :

- les images sont chargées puis normalisées ;
- elles sont redimensionnées pour entrer dans un backbone CNN ;
- un modèle pré-entraîné est adapté par transfer learning ;
- l'entraînement est suivi expérimentalement avec MLflow ;
- les performances sont évaluées par plusieurs métriques ;
- l'inférence peut être expliquée via des cartes d'attention de type Grad-CAM.

17 Conclusion

Le projet MedVision illustre comment des outils issus :

- de l'algèbre linéaire ;
- de l'analyse ;
- des probabilités ;
- et de l'optimisation ;

permettent de construire un pipeline moderne de computer vision pour l'imagerie médicale.

L'idée fondamentale est toujours la même :

transformer des images en représentations mathématiques pertinentes, puis apprendre automatiquement une règle de décision à partir des données.